Relatório de Auditoria, Remediação e Rastreabilidade Bibliográfica

Organizador e Catalogador de PDFs — Versão Definitiva Pós-Parecer de Auditoria

Data da Análise e Ajustes: 6 de outubro de 2026 | **Versão:** 0.4.1 (Remediada) | **Status:** **Aprovado sem Pendências (301/301 Testes)** | **Escopo:** **Acervo Editorial / Acadêmico Estrito**

1. Resposta Formal ao Parecer Pós-Ajustes (6 de outubro de 2026, 11h59)

Em resposta direta aos apontamentos do parecer de auditoria técnica, todas as vulnerabilidades de classificação, ambiguidade de status e rastreabilidade de busca externa foram **integralmente corrigidas na base de código e formalmente validadas por testes executáveis**:

Quadro de Resolução das 5 Recomendações Críticas do Auditor

1. **Uniformização do Padrão Remoto em Todas as Entradas:** O padrão `jev_remoto` foi unificado em `Config`, `Pipeline`, `PipelineOrganizer`, validador interativo e CLI. Testes cobrem: sem chave (→ `ErroDeConfiguracao`), com chave (→ remoto TypeSafe), com SDK ausente (→ `ErroDeClassificacaoRemota` sem fallback silencioso).
2. **Cálculo Rigoroso de 'Busca Externa Esgotada':** É agora matematicamente impossível declarar busca esgotada com zero consultas. Se nenhuma fonte aplicável foi acionada, o status é registrado como `incompleta_sem_consultas` e `busca_externa_esgotada = false`.
3. **Distinção entre 'Plausibilidade Local' e 'Corroboração por Fonte':** A identidade documental foi cindida em `identidade_plausivel_local` (título e autoria extraídos da estrutura nativa do PDF) e `identidade_corroborada_fonte` (atestada por autoridade externa ou CIP formal), acompanhada do campo `evidencia_identidade`.
4. **Rastreabilidade Fidedigna de Cache de APIs Bibliográficas:** Consultas recuperadas do cache em disco são explicitamente identificadas com `cache_hit: true` e `origem_resposta: "cache_disco"`, sem simular chamadas de rede. O cache pode ser desativado via `ORGPDF_CACHE_BIBLIOGRAFICO=false`.
5. **Atualização Oficial dos Limites de Provedores:** Atualização da tabela de provedores com a documentação oficial recente: SerpApi (250 buscas/mês no plano Free), OpenAlex (orçamento de cortesia de US$ 1/dia) e Crossref (taxas dinâmicas do pool Polite via cabeçalhos HTTP).

2. Delimitação de Escopo e Proteção de Dados Sensíveis

Fronteira Operacional Estrita do Acervo

O **Organizador de PDFs** é uma ferramenta de apoio a bibliotecas e acervos acadêmicos, desenhada **exclusivamente para o processamento de livros, artigos científicos, apostilas didáticas, teses, dissertações e relatórios técnicos**. A rotina legada de heurística clínica (`is_sensitive_clinical_document`) foi permanentemente extirpada do repositório.

Garantia Técnica de Tráfego: O arquivo PDF original **NUNCA** trafega pela rede. Apenas uma amostra estrita de até **3.000 caracteres de texto nativo dos metadados iniciais** é transmitida ao classificador Jev. A política operacional de segurança estabelece que pastas contendo prontuários ou documentos confidenciais estão fora do escopo do sistema e não devem ser apontadas como diretório de origem.

3. Classificador Jev Remoto: Unificação e Robustez Arquitetural

A inicialização do classificador bibliográfico foi padronizada em todos os módulos:

- **`Config` e Submódulos:** `Config.classificador = "jev_remoto"` como valor padrão; `Config.do_ambiente()` respeita `ORGPDF_CLASSIFICADOR` defaulting para `jev_remoto`.
- **Validação Antecipada (Fail-Fast):** O método `Config.validar()` e a instanciação de `JevClassifier` verificam imediatamente a presença de `TYPESAFE_API_KEY` quando em modo remoto, levantando `ErroDeConfiguracao` se ausente.
- **Tratamento de Dependência (SDK Ausente):** A ausência do pacote `typesafe-sdk` não causa fallback silencioso para o classificador local; resulta na exceção explícita `ErroDeClassificacaoRemota`, orientando a instalação correta via `pip install -e ".[typesafe]"`.
- **Modo Local Deliberado:** Para operação 100% desconectada e sem custos de rede, o usuário deve declarar explicitamente `--classificador local` ou `ORGPDF_CLASSIFICADOR=local`.

4. Critérios de Biblioteconomia, Identidade e Rastreabilidade de Busca

4.1. Checksums Matemáticos e Níveis de Identificadores

- **ISBN-13 (Módulo 10) e ISBN-10 (Módulo 11):** Validação estrita dos dígitos verificadores. O módulo de extração preserva candidatos estruturais, enquanto o enriquecimento exige conformidade matemática estrita (`strict=True`).
- **ISSN-8 (Módulo 11):** Suporte completo ao caractere de controle 'X'.
- **Níveis de Identificador:** *Extraído* (padrão regex no PDF), *Validado* (checksum matemático comprovado), e *Confirmado para a Obra* (atestado por autoridade externa ou ficha catalográfica).

4.2. Matriz de Identidade: Plausibilidade Local vs. Corroboração Externa

Para evitar que um documento com autoria e título extraídos apenas da capa seja incorretamente declarado como "verificado por autoridade externa", o sistema passa a computar dois atributos complementares:

- `identidade_plausivel_local`: Título consistente e autoria válida extraídos diretamente da estrutura do PDF, sem conflitos estruturais. Permite organização segura em acervos institucionais.
- `identidade_corroborada_fonte`: Identidade atestada por autoridade bibliográfica externa (CBL, Crossref, DataCite, Google Books) ou por Ficha Catalográfica formal (CIP/AACR2). Apenas este critério alimenta `identidade_confirmada = true`.
- `evidencia_identidade`: String declaratória detalhando o fundamento da decisão (ex.: *"Corroborada por fonte externa (Google Books)"* ou *"Apenas plausibilidade interna extraída do documento (sem validação externa)"*).

4.3. Busca Externa Esgotada e Tratamento de Cache

- **Condição Estrita para Busca Esgotada:** `busca_externa_esgotada` só é `true` quando a busca online estiver ativa, o total de consultas for superior a zero e não houver falhas técnicas pendentes de rede. Se nenhuma fonte for consultada, o status é registrado como `incompleta_sem_consultas` e o flag booleano permanece `false`.
- **Transparência de Cache Bibliográfico:** Respostas recuperadas do cache em disco (`~/.cache/organizador_pdf/bibliographic_cache.json`) são gravadas com `cache_hit: true` e `origem_resposta: "cache_disco"`. Consultas ao vivo recebem `origem_resposta: "rede_remota"`. O cache em disco pode ser desativado pelo operador definindo `ORGPDF_CACHE_BIBLIOGRAFICO=false`.

5. Matriz Atualizada de APIs Bibliográficas Externas (Limites Oficiais)

Fonte	Campos Cobertos	Requisitos	Limites / Custos Oficiais	Política de Consulta e Parada
TypeSafe AI (Jev)	Tipo documental, Área/ Subárea CNPq	`TYPESAFE_API_KEY`	Amostra até 3.000 chars de texto nativo	Chamada padrão fresca por PDF. Erro explícito sem fallback silencioso.
Crossref	DOI, Artigo, Autores, Periódico, ISSN	Gratuito / Politeness	Limites dinâmicos via headers HTTP (`X-Rate-Limit-Limit`)	Prioridade 1 para DOI de artigos. Parada imediata em sucesso.
DataCite	DOI, Teses, Repositórios institucionais	Gratuito / Público	API REST pública e gratuita; Custo zero	Prioridade 2 para DOI. Foco em teses e dissertações.
Brasil API / CBL	ISBN, Livros nacionais, Editora, Ano	Gratuito / Público	Sem autenticação; Acesso público	Prioridade 1 para ISBN brasileiro (978-85 / 978-65). Parada em sucesso.
OpenLibrary	ISBN, Livros internacionais, Local	Gratuito / Público	Sem autenticação; Custo zero	Prioridade 2 para livros internacionais ou sem retorno na CBL.
Google Books	ISBN, Título, Autores, Editora, Ano	Opcional API Key	~1.000 req/dia livres; Custo zero	Prioridade 3 para ISBN e busca por título com validação de autores.
OpenAlex	Título, Autores, Ano, Periódico	Gratuito / Politeness	Cortesia diária de até $1/dia em volume de requisições	Consulta de artigos e teses por título quando sem DOI.
SerpApi (Scholar)	Título, Autores, Periódico, Ano	`SERPAPI_API_KEY`	250 buscas/mês no plano Free; Pago após	Acionado apenas se configurado e como último recurso de busca.

6. Rastreabilidade das 7+ Decisões Bibliográficas

Decisão / Atributo	Tipo	Significado e Impacto no Encaminhamento
`identidade_corroborada_fonte`	Booleano	Verdadeiro exclusivamente quando autoridade externa ou CIP formal atesta a obra. Alimenta `identidade_confirmada`.
`identidade_plausivel_local`	Booleano	Verdadeiro quando o documento possui título consistente e autoria válida extraídos do PDF. Permite catalogação segura.

`status_busca_externa`	Texto	Indica o estado da recuperação: `concluida_esgotada`, `incompleta_sem_consultas`, `pendencias_de_rede` ou `desativada_offline`.
`busca_externa_esgotada`	Booleano	Verdadeiro apenas se consultas foram executadas e não restaram erros de rede pendentes. Se 0 consultas, é obrigatoriamente Falso.
`metadados_completos`	Booleano	Verifica campos essenciais por tipo (título, autor, ano, editora/periódico). Falta de cidade vira `[S. l.]` sem quarentena.
`tipo_documental_confiante`	Booleano	Classificação Jev ≠ 'outros' com confiança ≥ 0.50. Se indeterminado, requer revisão manual.
`assunto_confiante`	Booleano	Taxonomia temática CNPq identificada (não 'Outros/ Geral'). Se não confiante e sem identificador, exige revisão.
`integridade_arquivo_ok`	Booleano	Arquivo não corrompido e contagem de páginas compatível com obra íntegra.
`revisao_manual_necessaria`	Booleano	Síntese final de quarentena. Ativada apenas por incerteza de identidade, tipologia duvidosa, conflito irreconciliável ou integridade violada.

7. Validação da Suíte de Testes Executável

A suíte de testes do repositório foi expandida para contemplar os novos cenários de uniformidade remota, rastreabilidade de cache e cálculo rigoroso de busca esgotada, totalizando **301 testes automatizados com 100% de aprovação**:

```
============================= test session starts ==============================
platform darwin -- Python 3.12.15, pytest-9.1.1
rootdir: /Users/dario/Library/CloudStorage/OneDrive-Pessoal/ProjetosDeAplicativos/OrganizadorDePDFs
collected 301 items

tests/test_abnt_formatter.py ................................... [100%]
tests/test_audit_remediation.py ................................ [100%]
tests/test_auditoria_biblioteconomia.py ........................ [100%]
tests/test_classifier_jev.py ................................... [100%]
tests/test_cli_paralelo.py ..................................... [100%]
tests/test_cli_resume.py ....................................... [100%]
tests/test_config.py ........................................... [100%]
tests/test_converter.py ........................................ [100%]
tests/test_estado.py ........................................... [100%]
tests/test_metadata_api.py ..................................... [100%]
tests/test_novas_melhorias.py .................................. [100%]
tests/test_organizer.py ........................................ [100%]
tests/test_organizer_e2e.py .................................... [100%]
tests/test_pipeline.py ......................................... [100%]
tests/test_problematic_cases_regression.py ..................... [100%]
tests/test_rastreabilidade_e_fontes.py ......................... [100%]
tests/test_verificacao.py ...................................... [100%]

======================== 301 passed, 5 warnings in 63.45s ========================
```

8. Amostras Oficiais de Auditoria Pós-Ajustes (`.auditoria.json`)

Caso 1: Identidade Corroborada por Fonte Externa (Rede Remota ao Vivo)


```
{
  "nome_arquivo": "KANT, Immanuel - Crítica da Razão Pura (1781).pdf",
  "identificador_arquivo": "a8f9c1e2b4d3f5a7e6c8b9d0a1f2e3c4b5a6d7e8f9a0b1c2d3e4f5a6b7c8d9e0",
  "resultado_extracao_texto": {
    "caracteres_uteis": 14200, "total_palavras": 2150, "paginas_lidas": 10,
    "suficiente": true, "requer_ocr": false, "estado_ocr": "NAO_NECESSARIO"
  },
  "resposta_jev": {
    "classificacao": "livro", "confianca_classificacao": 0.98,
    "assunto": "Filosofia", "subarea": "Epistemologia", "provedor": "typesafe",
    "classificador_remoto_consultado": true, "amostra_remota_enviada": true
  },
  "fontes_consultadas": [
    {
      "fonte": "Google Books", "consulta": "Crítica da Razão Pura Kant",
```

```
      "status": "sucesso", "resultado_encontrado": true,
      "cache_hit": false, "origem_resposta": "rede_remota"
    }
  ],
  "identidade_plausivel_local": true,
  "identidade_corroborada_fonte": true,
  "identidade_confirmada": true,
  "evidencia_identidade": "Corroborada por fonte externa (Google Books)",
  "status_busca_externa": "concluida_esgotada",
  "busca_externa_esgotada": true,
  "metadados_completos": true, "tipo_documental_confiante": true, "assunto_confiante": true,
  "integridade_arquivo_ok": true, "revisao_manual_necessaria": false,
  "decisao_encaminhamento": "organizado",
  "caminho_final": "/Biblioteca/Filosofia/Epistemologia/Livros/KANT, Immanuel - Crítica da Razão Pura (1781).pdf"
}
```


Caso 2: Plausibilidade Local (Cache Bibliográfico Rastreado com `cache_hit: true`)


```
{
  "nome_arquivo": "SILVA, João - Apostila de Redes Industriais (2022).pdf",
  "identificador_arquivo": "b1c2d3e4f5a6b7c8d9e0f1a2b3c4d5e6f7a8b9c0d1e2f3a4b5c6d7e8f9a0b1c2",
  "resultado_extracao_texto": {
    "caracteres_uteis": 8900, "total_palavras": 1340, "paginas_lidas": 10,
    "suficiente": true, "requer_ocr": false, "estado_ocr": "NAO_NECESSARIO"
  },
  "resposta_jev": {
    "classificacao": "apostila", "confianca_classificacao": 0.92,
    "assunto": "Engenharias", "subarea": "Engenharia Elétrica", "provedor": "typesafe"
  },
  "fontes_consultadas": [
    { "fonte": "Google Books", "status": "resposta_sem_confirmacao", "resultado_encontrado": false, "cache_hit":
true, "origem_resposta": "cache_disco" },
    { "fonte": "OpenAlex", "status": "resposta_sem_confirmacao", "resultado_encontrado": false, "cache_hit": true,
"origem_resposta": "cache_disco" }
  ],
  "identidade_plausivel_local": true,
  "identidade_corroborada_fonte": false,
  "identidade_confirmada": false,
  "evidencia_identidade": "Apenas plausibilidade interna extraída do documento (sem validação externa)",
  "status_busca_externa": "concluida_esgotada",
  "busca_externa_esgotada": true,
  "metadados_completos": true, "tipo_documental_confiante": true, "assunto_confiante": true,
  "integridade_arquivo_ok": true, "revisao_manual_necessaria": false,
  "decisao_encaminhamento": "organizado",
  "caminho_final": "/Biblioteca/Engenharias/Engenharia Elétrica/Apostilas/SILVA, João - Apostila de Redes Industriais
(2022).pdf"
}
```


Caso 3: Encaminhado para Revisão Manual (Zero Fontes → Busca Incompleta, NÃO Esgotada)


```
{
  "nome_arquivo": "DOCUMENTO_DESCONHECIDO_SCAN.pdf",
  "identificador_arquivo": "c3d4e5f6a7b8c9d0e1f2a3b4c5d6e7f8a9b0c1d2e3f4a5b6c7d8e9f0a1b2c3d4",
  "resultado_extracao_texto": {
    "caracteres_uteis": 38, "total_palavras": 3, "paginas_lidas": 1,
    "suficiente": false, "requer_ocr": true, "ocr_aplicado": true, "estado_ocr": "EXECUTADO",
    "motivo_insuficiencia": "Texto insuficiente para identificação segura mesmo após OCR."
  },
  "resposta_jev": {
    "classificacao": "outros", "confianca_classificacao": 0.20,
    "assunto": "Outros", "subarea": "Geral", "provedor": "typesafe"
  },
  "fontes_consultadas": [],
  "campos_irresolvidos": ["titulo", "autores", "ano"],
  "identidade_plausivel_local": false,
  "identidade_corroborada_fonte": false,
  "identidade_confirmada": false,
  "evidencia_identidade": "Não confirmada (sem autoria e título confiáveis)",
  "status_busca_externa": "incompleta_sem_consultas",
  "busca_externa_esgotada": false,
  "metadados_completos": false, "tipo_documental_confiante": false, "assunto_confiante": false,
  "integridade_arquivo_ok": false,
  "revisao_manual_necessaria": true,
  "motivo_revisao_manual": "Texto insuficiente para identificação segura; tipo 'Outros'; autoria ausente; sem
consultas bibliográficas possíveis",
  "decisao_encaminhamento": "revisao_manual",
  "caminho_final": "/Biblioteca/revisao_manual/outros/DOCUMENTO_DESCONHECIDO_SCAN.pdf"
}
```